

# Rede de Crenças e Lógica Fuzzy

## Capítulo 15a

Prof. Dr. Tiago Araújo

# Independência

Duas variáveis aleatórias  $A$  e  $B$  são (absolutamente) independentes se  
 $P(A|B) = P(A)$

ou  $P(A, B) = P(A|B)P(B) = P(A)P(B)$   
por exemplo,  $A$  e  $B$  são duas moedas atiradas

Se  $n$  variáveis Booleanas são independentes, o conjunto completo é

$$P(X_1, \dots, X_n) = \prod_i P(X_i)$$

Portanto, pode ser especificado por apenas  $n$  número

A independência absoluta é uma exigência muito forte, raramente atendida

## Independência Condicional

Considerando o problema do dentista com três variáveis aleatórias:

*Toothache*, *Cavity* (cárie), *Catch* (sonda de aço prende em meu dente)

A distribuição conjunta completa tem  $2^3 - 1 = 7$  entradas independentes.

Se eu tenho uma *Cavity* (cárie), a probabilidade de a sonda prender dentro não depende do clima eu tenho *Toothache* (uma dor de dente):

$$(1) P(\textit{Catch} | \textit{Toothache}, \textit{Cavity}) = P(\textit{Catch} | \textit{Cavity})$$

Por exemplo, *Catch* é condicionalmente independente de *Toothache* dado *Cavity*:

A mesma independência se mantém se eu não tiver uma cárie:

$$(2) P(\textit{Catch} | \textit{Toothache}, \neg \textit{Cavity}) = P(\textit{Catch} | \neg \textit{Cavity})$$

## Independência Condicional

Declarações equivalentes a (1)

$$(1a) P(\textit{Toothache}|\textit{Catch}, \textit{Cavity}) = P(\textit{Toothache}|\textit{Cavity}) \text{ Por quê??}$$

$$(1b) P(\textit{Toothache}, \textit{Catch}|\textit{Cavity}) = P(\textit{Toothache}|\textit{Cavity})P(\textit{Catch}|\textit{Cavity})$$

Por quê??

A distribuição conjunta completa pode agora ser escrita como

$$\begin{aligned} \bar{\mathbf{P}}(\textit{Toothache}, \textit{Catch}, \textit{Cavity}) &= \mathbf{P}(\textit{Toothache}, \textit{Catch}|\textit{Cavity})\mathbf{P}(\textit{Cavity}) \\ &= \mathbf{P}(\textit{Toothache}|\textit{Cavity})\mathbf{P}(\textit{Catch}|\textit{Cavity})\mathbf{P}(\textit{Cavity}) \end{aligned}$$

Por exemplo,  $2 + 2 + 1 = 5$  números independentes (equações 1 e 2 remove 2)

# Independência Condicional

Declarações equivalentes a 1

$$\begin{aligned} P(\text{Toothache}|\text{Catch}, \text{Cavity}) \\ &= P(\text{Catch}|\text{Toothache}, \text{Cavity})P(\text{Toothache}|\text{Cavity})/P(\text{Catch}|\text{Cavity}) \\ &= P(\text{Catch}|\text{Cavity})P(\text{Toothache}|\text{Cavity})/P(\text{Catch}|\text{Cavity}) \text{ (de 1)} \\ &= P(\text{Toothache}|\text{Cavity}) \end{aligned}$$

(1b)  $P(\text{Toothache}, \text{Catch}|\text{Cavity}) = P(\text{Toothache}|\text{Cavity})P(\text{Catch}|\text{Cavity})$   
Por quê?

$$\begin{aligned} P(\text{Toothache}, \text{Catch}|\text{Cavity}) \\ &= P(\text{Toothache}|\text{Catch}, \text{Cavity})P(\text{Catch}|\text{Cavity}) \text{ (product rule)} \\ &= P(\text{Toothache}|\text{Cavity})P(\text{Catch}|\text{Cavity}) \text{ (de 1a)} \end{aligned}$$

## Redes de Crenças

Uma notação simples e gráfica para afirmações de independência condicional e, portanto, para a especificação compacta de distribuições conjuntas completas

Sintaxe:

- um conjunto de nós, um por variável

- um gráfico dirigido, acíclico (link  $\approx$  "influências diretas")

- uma distribuição condicional para cada nó dado seus pais:

$$P(X_i | Parents(X_i))$$

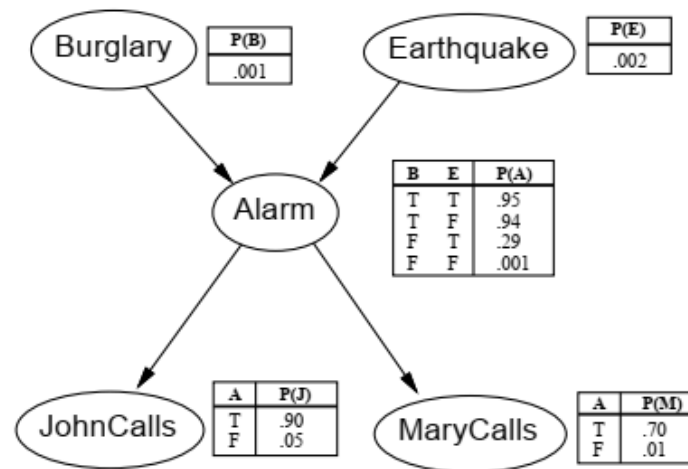
No caso mais simples, a distribuição condicional ressentiu-se como uma tabela de probabilidade condicional (CPT).

## Exemplo

Estou no trabalho, o vizinho John liga para dizer que meu alarme está tocando, mas a vizinha Mary não liga. Às vezes é desencadeado por pequenos terremotos. Há um assaltante?

Variáveis: *Burlar*, *Earthquake*, *Alarm*, *JohnCalls*, *MaryCalls*

A topologia da rede reflete o conhecimento "causal":



Nota:  $\leq k.\text{parents} \Rightarrow O(d^k n)$  numbers vs  $O(d^n)$

# Semânticas

A semântica "global" define a distribuição conjunta completa como o produto da distribuição condicional local:

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

Por exemplo,  $\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$   
 e.g.,  $P(J \wedge M \wedge A \wedge \neg B \wedge \neg E)$  **É dada por??**  
 =



## Semânticas

A semântica "global" define a distribuição conjunta completa como o produto da distribuição condicional local

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

Por exemplo,  $\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$


$$\begin{aligned} \text{e.g., } P(J \wedge M \wedge A \wedge \neg B \wedge \neg E) & \text{ \textbf{É dada por??} } \\ & = P(\neg B)P(\neg E)P(A|\neg B \wedge \neg E)P(J|A)P(M|A) \end{aligned}$$

Semântica "local": cada nó é condicionalmente independente de seus não-descendentes, dado que seus pais

Teorema: Semântica local  $\Leftrightarrow$  semântica global

## Manta de Markov

Cada nó é condicionalmente independente de todos os outros, dada a Manta de Markov: parents + children + children's parents



## Construindo a rede de crenças

Precisa de um método tal que uma série de afirmações locais de independência condicional garanta a necessária semântica global.

1. Escolha uma ordenação de variáveis  $X_1, \dots, X_n$
2. Para  $i = 1$  até  $n$

adicione  $X_i$  na rede

selecione parents  $= \Pi_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$  de

$$\mathbf{P}(X_i | \text{Parents}(X_i)) = \mathbf{P}(X_i | X_1, \dots, X_{i-1})$$

Essa escolha de pais garante a semântica global:

$$\mathbf{P}(X_1, \dots, X_n) = \Pi_{i=1}^n \mathbf{P}(X_i | X_1, \dots, X_{i-1}) \quad (\text{regra da cadeia})$$

$$= \Pi_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i)) \quad \text{por construção}$$

## Exemplo

Suponha que nós escolhemos ordenar  $M, J, A, B, E$


MaryCalls

JohnCalls

$$P(J|M) = P(J)?$$

## Exemplo

Suponha que nós escolhemos ordenar  $M, J, A, B, E$




$P(J|M) = P(J)$ ? *Não*

$P(A|J, M) = P(A|J)$ ?  $P(A|J, M) = P(A)$ ?

## Exemplo

Suponha que nós escolhemos ordenar  $M, J, A, B, E$



$$P(J|M) = P(J)? \quad \text{Não}$$


$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)? \quad \text{Não}$$

$$P(B|A, J, M) = P(B|A)?$$

$$P(B|A, J, M) = P(B)?$$

## Exemplo

Suponha que nós escolhemos ordenar  $M, J, A, B, E$



$P(J|M) = P(J)$ ? Não

$P(A|J, M) = P(A|J)$ ?  $P(A|J, M) = P(A)$ ? Não

$P(B|A, J, M) = P(B|A)$ ? Sim


$P(B|A, J, M) = P(B)$ ? Não

$P(E|B, A, J, M) = P(E|A)$ ?

$P(E|B, A, J, M) = P(E|A, B)$ ?

## Exemplo

Suponha que nós escolhemos ordenar  $M, J, A, B, E$



$P(J|M) = P(J)$ ? Não

$P(A|J, M) = P(A|J)$ ?  $P(A|J, M) = P(A)$ ? Não

$P(B|A, J, M) = P(B|A)$ ? Sim

$P(B|A, J, M) = P(B)$ ? Não

$P(E|B, A, J, M) = P(E|A)$ ? Não

$P(E|B, A, J, M) = P(E|A, B)$ ? Sim

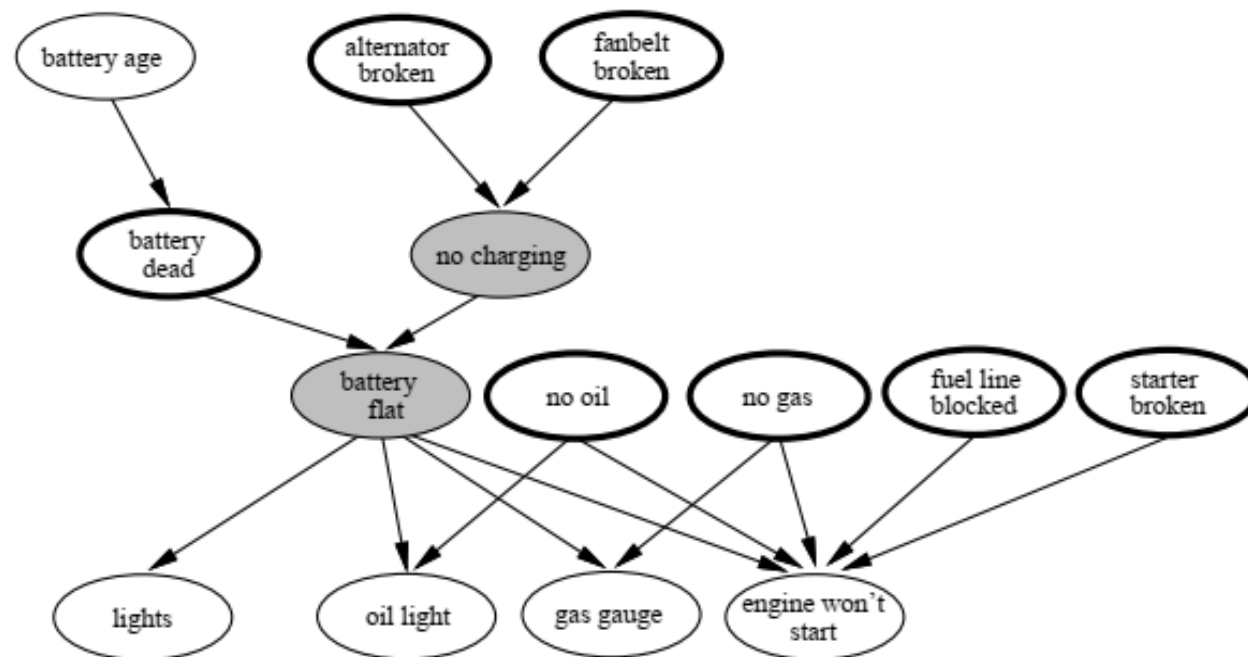


## Exemplo: Diagnóstico de Carros

Evidência inicial: o motor não pega

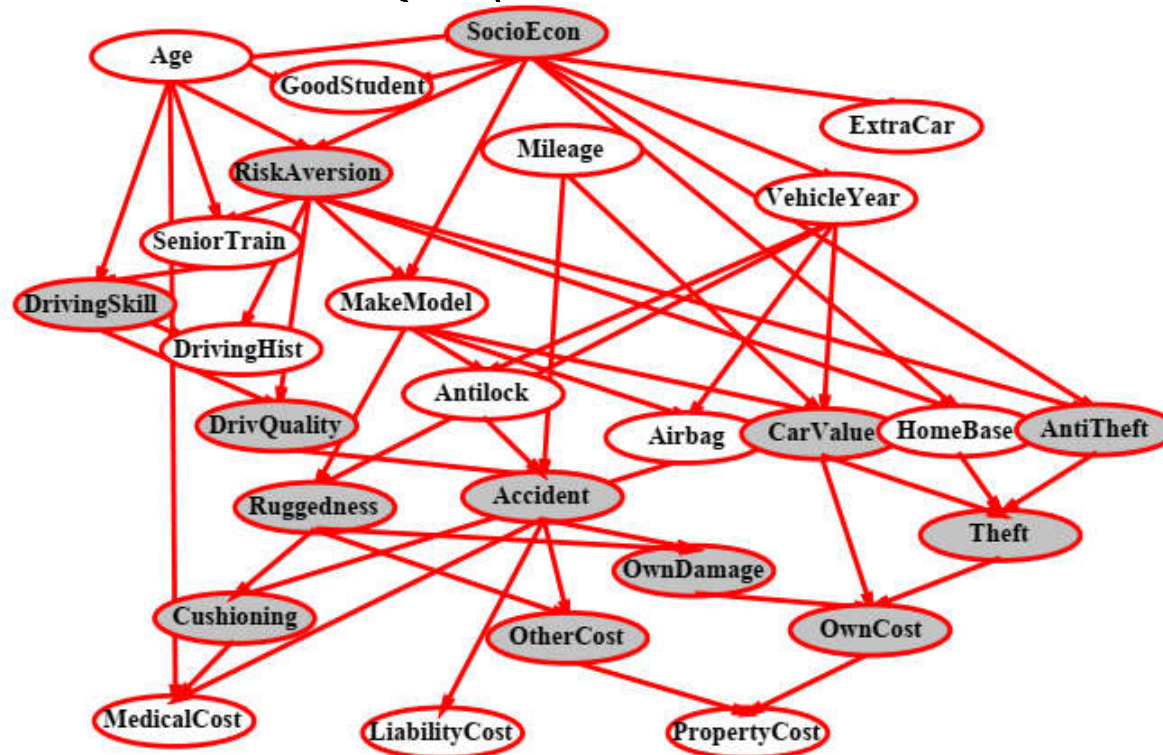
Variáveis testáveis (ovais finos), variáveis de diagnóstico (ovais grossos)

Variáveis ocultas (sombreadas) garantem estrutura esparsa, reduzem parâmetros



# Exemplo: Seguro do carro

Prever custos de reclamação (médicos, responsabilidade civil, propriedade) com dados no formulário de solicitação (outros nós não sombreados)



## Distribuições condicionais compactas

CPT cresce exponencialmente com o no.de pais CPT torna-se infinito com pais ou filhos de valor contínuo

Solução: distribuições canônicas que são definidas de forma compacta

Os nós determinísticos são o caso mais simples:

$$X = f(\text{Parents}(X)) \text{ para algumas funções } f$$

Por exemplo: Funções Booleanas

$$\text{NorthAmerican} \Leftrightarrow \text{Canadian} \vee \text{US} \vee \text{Mexican}$$

Por exemplo, relações numerais entre variáveis contínuas

$$\frac{\partial \text{Level}}{\partial t} = \text{inflow} + \text{precipitation} - \text{outflow} - \text{evaporation}$$

## Distribuições condicionais compactas

Noisy-OR distribuições modelo de múltiplas causas não-interativas

- 1) Pais  $U_1 \dots U_k$  incluindo todas as causas (pode adicionar um (nó de fuga
- 2) Probabilidade de falha independente  $q_i$  para cada causa isolada


$$\Rightarrow P(X|U_1 \dots U_j, \neg U_{j+1} \dots \neg U_k) = 1 - \prod_{i=1}^j q_i$$

<i>Cold</i>	<i>Flu</i>	<i>Malaria</i>	$P(\text{Fever})$	$P(\neg \text{Fever})$
F	F	F	<b>0.0</b>	1.0
F	F	T	0.9	<b>0.1</b>
F	T	F	0.8	<b>0.2</b>
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	<b>0.6</b>
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

Números de parâmetros *lineares* em número de pais

## Redes híbridas (discretas+contínuas)

Dicreto (*subsidy?* e *Buys?*); contínuo (*Harvest* e *Cost*)



Opção 1: dicretização possivelmente grandes erros, CPT grande

Opção 2: famílias canônicas finamente parametrizadas1) Variável contínua, pais discretos+ contínuos (por exemplo, *Cost*)

2) Variável discreta, pais contínuos (por exemplo, *Buys?*)

## Variáveis Filhas Contínuas


Necessidade de uma função de densidade condicional para a variável filha dada aos pais contínuos, para cada possível atribuição aos pais discretos.

O mais comum é o modelo *linear gaussiano*, por exemplo

$$\begin{aligned} P(Cost = c | Harvest = h, Subsidy? = true) \\ &= N(a_t h + b_t, \sigma_t)(c) \\ &= \frac{1}{\sigma_t \sqrt{2\pi}} \exp \left( -\frac{1}{2} \left( \frac{c - (a_t h + b_t)}{\sigma_t} \right)^2 \right) \end{aligned}$$

O *Cost* médio varia linearmente com a *Harvest*, a variação é fixa. A variação linear não é razoável em toda a faixa, mas funciona OK se a faixa provável de *Harvest* for estreita.

## Variáveis Filhas Contínuas



Rede totalmente contínua com distribuições LG

⇒ conjunto completo é uma Gaussiana multivariável

A rede LG discreta + contínua é uma rede Gaussiana condicional, ou seja; uma Gaussiana multivariada sobre todas as variáveis contínuas para cada combinação de valores discretos de variáveis

## Variável discreta com pais contínuos

Probabilidade de *Buy?* dado o *Cost* deve ser um limite "suave":

epsfxsize=0,6

`fig{\i1}\{probit.ps}\{file{\i1}\graphs}\{probit.ps}`

A distribuição Probit usa integral de Gaussian:

$$\Phi(x) = \int_{-\infty}^x N(0,1)(x) dx$$

$$P(\text{Buys? true given Cost } c) = \Phi\left(\frac{-c + \mu}{\sigma}\right)$$

Pode ver como limiar duro cuja localização está sujeita a ruído




## Variáveis Discretas cont.

A distribuição Sigmoid (ou logit) também é utilizada em redes neurais:

$$P(Buys? = true \mid Cost = c) = \frac{1}{1 + \exp(-2\frac{-c+\mu}{\sigma})}$$

O Sigmoid tem forma semelhante à sonda, mas com caudas muito mais longas:



## Tarefas de Inferência

Consultas simples: calcular marginal posterior  $P(X_i | \mathbf{E} = \mathbf{e})$

Por exemplo  $P(\text{NoGas} | \text{Gauge} = \text{empty}, \text{Lights} = \text{on}, \text{Starts} = \text{false})$

Consultas Conjuntivas:  $P(X_i, X_j | \mathbf{E} = \mathbf{e}) = P(X_i | \mathbf{E} = \mathbf{e})P(X_j | X_i, \mathbf{E} = \mathbf{e})$

Decisões ótimas: as redes de decisão incluem informações de utilidade pública; inferência probabilística necessária para

Valores de informação: quais evidências a serem buscadas a seguir?

Análise de sensibilidade: quais valores de probabilidade são mais críticos?

Explicação: por que eu preciso de um novo motor de arranque?

## Inferência por enumeração

Uma forma ligeiramente inteligente de extrair variáveis da junta sem construir sua representação explícita

Consulta simples sobre a rede de arrombamento:

$$\begin{aligned}
 & \mathbf{P}(B|J = \text{true}, M = \text{true}) \\
 &= \mathbf{P}(B, J = \text{true}, M = \text{true}) / P(J = \text{true}, M = \text{true}) \\
 &= \alpha \mathbf{P}(B, J = \text{true}, M = \text{true}) \\
 &= \alpha \sum_e \sum_a \mathbf{P}(B, e, a, J = \text{true}, M = \text{true})
 \end{aligned}$$

Reescrever entradas conjuntas completas usando o produto das entradas do CPT:

$$\begin{aligned}
 & P(B = \text{true} | J = \text{true}, M = \text{true}) \\
 &= \alpha \sum_e \sum_a P(B = \text{true}) P(e) P(a | B = \text{true}, e) P(J = \text{true} | a) P(M = \text{true} | a) \\
 &= \alpha P(B = \text{true}) \sum_e P(e) \sum_a P(a | B = \text{true}, e) P(J = \text{true} | a) P(M = \text{true} | a)
 \end{aligned}$$

## Algoritmo de Enumeração

Exaustiva enumeração em profundidade:  $O(n)$  espaço,  $O(d^n)$  tempo

**ENUMERATIONASK**( $X, \mathbf{e}, bn$ ) **returns** a distribution over  $X$

**inputs:**  $X$ , the query variable

$\mathbf{e}$ , evidence specified as an event

$bn$ , a belief network specifying joint distribution  $\mathbf{P}(X_1, \dots, X_n)$

$Q(x) \leftarrow$  a distribution over  $X$

**for each** value  $x_i$  of  $X$  **do**

    extend  $\mathbf{e}$  with value  $x_i$  for  $X$

$Q(x_i) \leftarrow \text{ENUMERATEALL}(\text{VARS}[bn], \mathbf{e})$

**return**  $\text{NORMALIZE}(Q(X))$

---

**ENUMERATEALL**( $vars, \mathbf{e}$ ) **returns** a real number

**if**  $\text{EMPTY?}(vars)$  **then return** 1.0

**else do**

$Y \leftarrow \text{FIRST}(vars)$

**if**  $Y$  has value  $y$  in  $\mathbf{e}$

**then return**  $P(y \mid Pa(Y)) \times \text{ENUMERATEALL}(\text{REST}(vars), \mathbf{e})$

**else return**  $\sum_y P(y \mid Pa(Y)) \times \text{ENUMERATEALL}(\text{REST}(vars), \mathbf{e}_y)$

            where  $\mathbf{e}_y$  is  $\mathbf{e}$  extended with  $Y = y$

## Inferência por eliminação de variável

A enumeração é ineficiente: cálculo repetido

Por exemplo cálculo  $P(J = \text{true}|a)P(M = \text{true}|a)$  para cada valor de  $e$

Eliminação de variáveis: realizar totalizações da direita para a esquerda, armazenando resultados intermediários (fatores) para evitar a recomputação

$$\begin{aligned}
 &P(B|J = \text{true}, M = \text{true}) \\
 &= \alpha \underbrace{P(B)}_B \underbrace{\sum_e P(e)}_E \underbrace{\sum_a P(a|B, e)}_A \underbrace{P(J = \text{true}|a)}_J \underbrace{P(M = \text{true}|a)}_M \\
 &= \alpha P(B) \sum_e P(e) \sum_a P(a|B, e) P(J = \text{true}|a) f_M(a) \\
 &= \alpha P(B) \sum_e P(e) \sum_a P(a|B, e) f_J(a) f_M(a) \\
 &= \alpha P(B) \sum_e P(e) \sum_a f_A(a, b, e) f_J(a) f_M(a) \\
 &= \alpha P(B) \sum_e P(e) f_{\bar{A}JM}(b, e) \text{ (sum out } A) \\
 &= \alpha P(B) f_{\bar{E}\bar{A}JM}(b) \text{ (sum out } E) \\
 &= \alpha f_B(b) \times f_{\bar{E}\bar{A}JM}(b)
 \end{aligned}$$

## Eliminação de Variável: Operações Básicas

- Produto pontual dos fatores  $f_1$  e  $f_2$ :

$$\begin{aligned} f_1(x_1, \dots, x_j, y_1, \dots, y_k) \times f_2(y_1, \dots, y_k, z_1, \dots, z_l) \\ = f(x_1, \dots, x_j, y_1, \dots, y_k, z_1, \dots, z_l) \end{aligned}$$

Por exemplo,  $f_1(a, b) \times f_2(b, c) = f(a, b, c)$

Soma de uma variável a partir de um produto de fatores: mover qualquer fator constante para fora da soma:

$$\sum_x f_1 \times \dots \times f_k = f_1 \times \dots \times f_i \sum_x f_{i+1} \times \dots \times f_k = f_1 \times \dots \times f_i \times f_{\bar{X}}$$

assumindo  $f_1, \dots, f_i$  não dependem de  $X$

## Algoritmo de Eliminação de Variável


```
function ELIMINATIONASK( $X, e, bn$ ) returns a distribution over  $X$   
  inputs:  $X$ , the query variable  
            $e$ , evidence specified as an event  
            $bn$ , a belief network specifying joint distribution  $P(X_1, \dots, X_n)$   
  
  if  $X \in e$  then return observed point distribution for  $X$   
   $factors \leftarrow []$ ;  $vars \leftarrow \text{REVERSE}(\text{VARS}[bn])$   
  for each  $var$  in  $vars$  do  
     $factors \leftarrow [\text{MAKEFACTOR}(var, e) | factors]$   
    if  $var$  is a hidden variable then  $factors \leftarrow \text{SUMOUT}(var, factors)$   
  return  $\text{NORMALIZE}(\text{POINTWISEPRODUCT}(factors))$ 
```

## Complexidade da inferência exata

Redes conectadas individualmente ou (politrizes) :  
 quaisquer dois nós são conectados por, no máximo, um caminho (não direcionado)  
 Os custos de tempo e espaço da eliminação variável são

Multiplicar as redes conectadas:  
 pode reduzir o 3SAT à inferência exata  $\Rightarrow$  NP-Difícil  
 equivalente a *contar* os modelos 3SAT  $\Rightarrow$  #P- Completo

1.  $A \vee B \vee C$
2.  $C \vee D \vee \sim A$
3.  $B \vee C \vee \sim D$





## Inferência por simulação estocástica

Ideia básica:

1) Tirar  $N$  amostras de uma distribuição de amostras  $S$

2) Calcule uma probabilidade posterior aproximada  $\hat{P}$

Mostre que isto converge para a verdadeira probabilidade  $P$

Resumo:

- Amostragem a partir de uma rede vazia
- Rejeição de amostras: rejeitar amostras que discordam das provas
- Ponderação da probabilidade: usar provas para pesar amostras
- MCMC: amostra de um processo estocástico cuja distribuição estacionária insere o verdadeiro posterior

## Amostragem a partir de uma rede vazia

```

function PRIORSAMPLE(bn) returns an event sampled from  $P(X_1, \dots, X_n)$  specified by bn
  x  $\leftarrow$  an event with n elements
  for i = 1 to n do
    xi  $\leftarrow$  a random sample from  $P(X_i \mid \text{Parents}(X_i))$ 
  return x

```

$P(\text{Cloudy}) = \langle 0.5, 0.5 \rangle$

sample  $\rightarrow \text{true}$

$P(\text{Sprinkler} \mid \text{Cloudy}) = \langle 0.1, 0.9 \rangle$

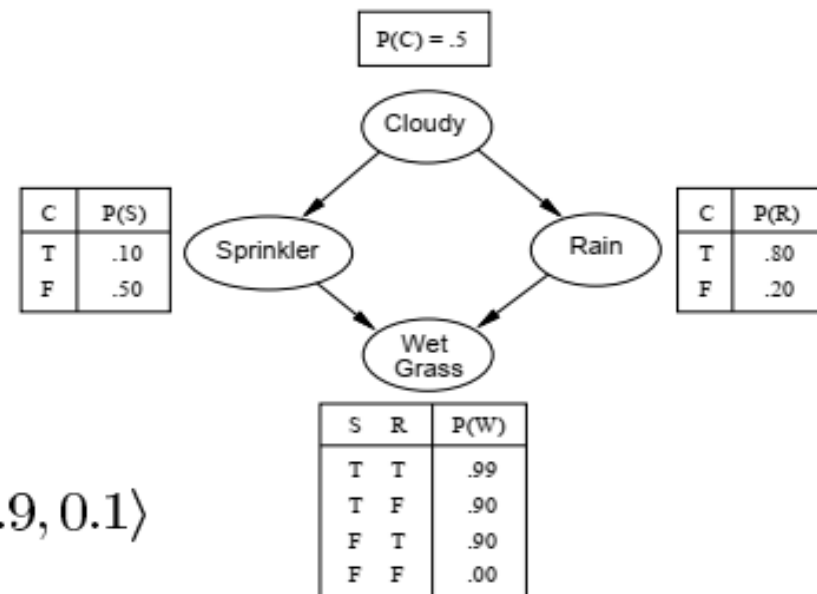
sample  $\rightarrow \text{false}$

$P(\text{Rain} \mid \text{Cloudy}) = \langle 0.8, 0.2 \rangle$

sample  $\rightarrow \text{true}$

$P(\text{WetGrass} \mid \neg \text{Sprinkler}, \text{Rain}) = \langle 0.9, 0.1 \rangle$

sample  $\rightarrow \text{true}$



## Amostragem a partir de uma rede vazia

Probabilidade de que o *PRIORSAMPLE* gere um determinado evento

$$S_{PS}(x_1 \dots x_n) = \prod_{i=1}^n P(x_i | \text{Parents}(X_i)) = P(x_1 \dots x_n)$$

isto é, então a probabilidade anterior verdadeira

Seja  $N_{PS}(\mathbf{Y}=\mathbf{y})$  número de amostras geradas para as quais  $\mathbf{Y}=\mathbf{y}$  para qualquer conjunto de variáveis  $\mathbf{Y}$ .

Então  $\hat{P}(\mathbf{Y}=\mathbf{y}) = N_{PS}(\mathbf{Y}=\mathbf{y})/N$  e

$$\begin{aligned} \lim_{N \rightarrow \infty} \hat{P}(\mathbf{Y}=\mathbf{y}) &= \sum_{\mathbf{h}} S_{PS}(\mathbf{Y}=\mathbf{y}, \mathbf{H}=\mathbf{h}) \\ &= \sum_{\mathbf{h}} P(\mathbf{Y}=\mathbf{y}, \mathbf{H}=\mathbf{h}) \\ &= P(\mathbf{Y}=\mathbf{y}) \end{aligned}$$

Ou seja, as estimativas derivadas do *PRIORSAMPLE* são consistentes

## Rejeição de amostra

$\hat{P}(X|e)$  estimado a partir de amostra de acordo com o **e**

```

function REJECTIONSAMPLING( $X, e, bm, N$ ) returns an approximation to  $P(X|e)$ 
   $N[X] \leftarrow$  a vector of counts over  $X$ , initially zero
  for  $j = 1$  to  $N$  do
     $x \leftarrow$  PRIORSAMPLE( $bm$ )
    if  $x$  is consistent with  $e$  then
       $N[x] \leftarrow N[x] + 1$  where  $x$  is the value of  $X$  in  $x$ 
  return NORMALIZE( $N[X]$ )

```

Por exemplo, estimativa  $P(Rain|Sprinkler = true)$  usando 100 amostras 27 amostras têm  $Sprinkler = true$

Desses, 8 têm  $Rain = true$  19 têm  $Rain = false$ .

$$\hat{P}(Rain|Sprinkler = true) = \text{NORMALIZE}(\langle 8, 19 \rangle) = \langle 0.296, 0.704 \rangle$$

Semelhante ao procedimento básico de estimativa empírica do mundo real

## Análises de rejeição de amostras


$$\begin{aligned}
 \hat{P}(X|\mathbf{e}) &= \mathbf{N}_{PS}(X, \mathbf{e}) && \text{(algoritmo defn)} \\
 &= \mathbf{N}_{PS}(X, \mathbf{e}) / N_{PS}(\mathbf{e}) && \text{(normalizado por } N_{PS}(\mathbf{e}) \text{)} \\
 &\approx \mathbf{P}(X, \mathbf{e}) / P(\mathbf{e}) && \text{(propriedade de } PRIORSAMPLE \text{)} \\
 &= \mathbf{P}(X|\mathbf{e}) && \text{, (def. De probabilidade condicional)}
 \end{aligned}$$

Assim, a rejeição de amostras retorna estimativas posteriores consistentes.

Problema: desesperadamente caro se  $P(\mathbf{e})$  for pequeno

# Exemplo de ponderação da probabilidade

Estimativa  $P(Rain | Sprinkler = true, WetGrass = true)$



## Exemplo de ponderação da probabilidade cont

Processo de geração de amostras:

1.  $w \leftarrow 1.0$
2. Amostra  $\mathbf{P}(\textit{Cloudy}) = \langle 0.5, 0.5 \rangle$ ; diz *true*
3. *Sprinkler true*, então  
 $w \leftarrow w \times P(\textit{Sprinkler} = \textit{true} | \textit{Cloudy} = \textit{true}) = 0.1$
4. Amostra  $\mathbf{P}(\textit{Rain} | \textit{Cloudy} = \textit{true}) = \langle 0.8, 0.2 \rangle$ ; diz *true*
5. *WetGrass* tem valor *true*, então  
 $w \leftarrow w \times P(\textit{WetGrass} = \textit{true} | \textit{Sprinkler} = \textit{true}, \textit{Rain} = \textit{true}) = 0.099$

# Análise de Ponderação de Probabilidade

A probabilidade de amostragem para *WEIGHTEDSAMPLE* é

$$S_{WS}(\mathbf{y}, \mathbf{e}) = \prod_{i=1}^l P(y_i | \text{Parents}(Y_i))$$

Nota: presta atenção à evidência apenas em *ancestors*

⇒ em algum lugar "entre" a distribuição prévia e posterior

Peso para uma determinada amostra  $\mathbf{y}$ ,  $\mathbf{e}$  é

$$\bar{w}(\mathbf{y}, \mathbf{e}) = \prod_{i=1}^m P(e_i | \text{Parents}(E_i))$$

A probabilidade de amostragem ponderada é

$$\begin{aligned} S_{WS}(\mathbf{y}, \mathbf{e}) \bar{w}(\mathbf{y}, \mathbf{e}) \\ &= \prod_{i=1}^l P(y_i | \text{Parents}(Y_i)) \prod_{i=1}^m P(e_i | \text{Parents}(E_i)) \\ &= P(\mathbf{y}, \mathbf{e}) \quad (\text{por semântica global padrão de rede}) \end{aligned}$$

Portanto, a ponderação de probabilidade de retorno estimativas consistentes, mas o desempenho ainda se degrada com muitas variáveis de evidência



## Inferência aproximada usando MCMC

“State” da rede = atribuição atual a todas as variáveis

Gerar o próximo estado por amostragem de uma variável dada a manta de Markov

Amostra cada variável por sua vez, mantendo as evidências fixas

```
function MCMC-Ask( $X, e, bn, N$ ) returns an approximation to  $P(X|e)$ 
  local variables:  $N[X]$ , a vector of counts over  $X$ , initially zero
                    $Y$ , the nonevidence variables in  $bn$ 
                    $x$ , the current state of the network, initially copied from  $e$ 

  initialize  $x$  with random values for the variables in  $Y$ 
  for  $j = 1$  to  $N$  do
     $N[x] \leftarrow N[x] + 1$  where  $x$  is the value of  $X$  in  $x$ 
    for each  $Y_i$  in  $Y$  do
      sample the value of  $Y_i$  in  $x$  from  $P(Y_i|MB(Y_i))$  given the values of  $MB(Y_i)$  in  $x$ 
  return NORMALIZE( $N[X]$ )
```

Aproxima-se de uma distribuição estacionária: a fração de tempo de longo prazo gasta em cada estado é exatamente proporcional à sua probabilidade posterior

## Exemplo MCMC


Estimativa  $P(Rain | Sprinkler = true, WetGrass = true)$

Amostra *Cloudy* então *Rain* , repete .

Número de contagem de tempo *Rain* é verdadeiro e falso na amostra

Manta de Markov de *Cloudy* é *Sprinkler* e *Rain*

Manta de Markov de *Rain* é *Cloudy* , *Sprinkler* e *WetGrass*



## Exemplo MCMC cont.

Estado inicial aleatório:  $Cloudy = true$  e  $Rain = false$

1.  $P(Cloudy|MB(Cloudy)) = P(Cloudy|Sprinkler, \neg Rain)$   
amostra  $\rightarrow false$
2.  $P(Rain|MB(Rain)) = P(Rain|\neg Cloudy, Sprinkler, WetGrass)$   
amostra  $\rightarrow true$

Visite 100 estados

31 tem  $Rain = true$ , 69 tem  $Rain = false$

$$\begin{aligned} \hat{P}(Rain|Sprinkler = true, WetGrass = true) \\ = \text{NORMALIZE}(\langle 31, 69 \rangle) = \langle 0.31, 0.69 \rangle \end{aligned}$$

## Análise MCMC: Resumo

Probabilidade de transição  $q(\mathbf{y} \rightarrow \mathbf{y}')$

Probabilidade de ocupação  $\pi_t(\mathbf{y})$  no momento  $t$

A condição de equilíbrio em  $\pi_t$  define a distribuição estacionária  $\pi(\mathbf{y})$

Nota: a distribuição estacionária depende da escolha de  $q(\mathbf{y} \rightarrow \mathbf{y}')$

O equilíbrio detalhado dos estados em pares garante o equilíbrio

Probabilidade de transição de amostragem de Gibbs:

amostragem de cada variável, dados os valores atuais de todas as outras

⇒ balanço detalhado com o verdadeiro posterior

Para redes Bayesianas, a amostragem Gibbs reduz a amostragem condicionada na manta Markov de cada variável

## Distribuição estacionária

$\pi_t(\mathbf{y})$  = probabilidade no estado  $\mathbf{y}$  no tempo  $t$

$\pi_{t+1}(\mathbf{y}')$  = probabilidade no estado  $\mathbf{y}'$  no tempo  $t+1$

$\pi_{t+1}$  em termos de  $\pi_t$  e  $q(\mathbf{y} \rightarrow \mathbf{y}')$

$$\pi_{t+1}(\mathbf{y}') = \sum_{\mathbf{y}} \pi_t(\mathbf{y}) q(\mathbf{y} \rightarrow \mathbf{y}')$$

Distribuição estacionária:  $\pi_t = \pi_{t+1} = \pi$

$$\pi(\mathbf{y}') \stackrel{\pi}{=} \sum_{\mathbf{y}} \pi(\mathbf{y}) q(\mathbf{y} \rightarrow \mathbf{y}') \quad \text{para todo } \mathbf{y}'$$

Se  $\pi$  existe, e é único (específico para  $q(\mathbf{y} \rightarrow \mathbf{y}')$  )

Em equilíbrio, esperado “outflow” = esperado “inflow”.

## Balanço Detalhado

“Outflow” = “inflow” para cada par de estados:

$$\pi(\mathbf{y})q(\mathbf{y} \rightarrow \mathbf{y}') = \pi(\mathbf{y}')q(\mathbf{y}' \rightarrow \mathbf{y}) \quad \text{para todos } \mathbf{y}, \mathbf{y}'$$

Balanço detalhado  $\Rightarrow$  estacionário:

$$\begin{aligned} \sum_{\mathbf{y}} \pi(\mathbf{y})q(\mathbf{y} \rightarrow \mathbf{y}') &= \sum_{\mathbf{y}} \pi(\mathbf{y}')q(\mathbf{y}' \rightarrow \mathbf{y}) \\ &= \pi(\mathbf{y}') \sum_{\mathbf{y}} q(\mathbf{y}' \rightarrow \mathbf{y}) \\ &= \pi(\mathbf{y}') \end{aligned}$$

Os algoritmos MCMC normalmente são construídos projetando uma probabilidade de transição  $q$  que está em equilíbrio detalhado com o desejado  $\pi$

## Amostras Gibbs

Amostra cada variável por sua vez, dadas *todas as outras variáveis*

Amostra  $Y_i$ , deixe  $\bar{Y}_i$  ser todas as outras variáveis não evidenciais

Os valores atuais são  $y_i$  e  $\bar{y}_i$  ;  $\mathbf{e}$  é fixa

A probabilidade de transição é dada por

$$q(\mathbf{y} \rightarrow \mathbf{y}') = q(y_i, \bar{y}_i \rightarrow y'_i, \bar{y}_i) = P(y'_i | \bar{y}_i, \mathbf{e})$$

Isto dá um equilíbrio detalhado com o verdadeiro posterior  $P(\mathbf{y} | \mathbf{e})$ :

$$\begin{aligned} \pi(\mathbf{y})q(\mathbf{y} \rightarrow \mathbf{y}') &= P(\mathbf{y} | \mathbf{e})P(y'_i | \bar{y}_i, \mathbf{e}) = P(y_i, \bar{y}_i | \mathbf{e})P(y'_i | \bar{y}_i, \mathbf{e}) \\ &= P(y_i | \bar{y}_i, \mathbf{e})P(\bar{y}_i | \mathbf{e})P(y'_i | \bar{y}_i, \mathbf{e}) \quad (\text{regra da cadeia}) \\ &= P(y_i | \bar{y}_i, \mathbf{e})P(y'_i, \bar{y}_i | \mathbf{e}) \quad (\text{regras da corrente ao contrário}) \\ &= q(\mathbf{y}' \rightarrow \mathbf{y})\pi(\mathbf{y}') = \pi(\mathbf{y}')q(\mathbf{y}' \rightarrow \mathbf{y}) \end{aligned}$$

## Amostra manto de Markov

Uma variável é independente de todas as outras, dado seu manto Markov:

$$P(y'_i | \bar{y}_i, \mathbf{e}) = P(y'_i | MB(Y_i))$$

A probabilidade dada pela manto Markov é calculada da seguinte forma:

$$P(y'_i | MB(Y_i)) = P(y'_i | Parents(Y_i)) \prod_{Z_j \in Children(Y_i)} P(z_j | Parents(Z_j))$$

Assim, o cálculo da distribuição de amostras sobre  $Y_i$  para cada virada requer apenas multiplicações de  $cd$  se  $Y_i$ ,  $c$  filhos e  $d$  valores ; pode armazená-la em cache se  $c$  não for muito grandes.

Principais problemas computacionais:

- 1) Difícil dizer se a convergência foi alcançada.
- 2) pode ser um desperdício se o manto de Maskov for grande:  
 $P(Y_i | MB(Y_i))$  não terá muitas chances (lei de grandes números)



## Performance de algoritmos de aproximação

Aproximação absoluta:  $|P(X|e) - \hat{P}(X|e)| < \epsilon$

Aproximação relativa:  $\frac{|P(X|e) - \hat{P}(X|e)|}{P(X|e)} \leq \epsilon$

Relativa  $\Rightarrow$  absoluta desde  $0 \leq P \leq 1$  ( pode ser  $O(2^{-n})$  )

Algoritmos aleatórios podem falhar com probabilidades no máximo  $\delta$

Aproximação poli-time:  $\text{poly}(n, \epsilon^{-1}, \log \delta^{-1})$

Teorema (Dagum e Luby, 1993): tanto a aproximação absoluta quanto a relativa para algoritmos determinísticos ou randomizados são NP\_hard para qualquer  $\epsilon, \delta < 0.5$   
(Aproximação absoluta de poli-times sem evidência -- limites Chernoff)

# Lógica Fuzzy

- É a lógica baseada em análises de informações estritamente qualitativas. Isto é feito de forma que a decisão não se resume entre um 'sim' e um 'não', mas, também considera abstrações do tipo 'próximo de', 'em torno de', 'muito alto', 'bem baixo', etc.

# Lógica Fuzzy

- Exemplo: Homens de meia idade
- Lógica Clássica:
- Se  $40 \leq \text{Idade} \leq 55$  então Homem meia idade
- Lógica fuzzy:

Idade	35	40	45	50	55
Grau de pertinência	0,0	0,5	1,0	0,5	0,0


# Conjuntos Fuzzy

- Um conjunto fuzzy  $X$  em um universo de discurso  $U$  é caracterizado por uma função que assume valores no intervalo  $[0,1]$

$$\mu_X(u) \in [0,1], \forall u \in U$$


# Conjuntos Fuzzy

- Funções de pertinência
  - Triangular
  - Trapezoidal
  - Sino
  - Gaussiana
  - Sigmoidal



# Conjuntos Fuzzy

- Contínua



# Conjuntos Fuzzy

- Discreta

$$F = \{(u, \mu_F(u)), u \in U\}$$

- Notação

$$F = \left\{ \frac{\mu_F(u)}{u}, u \in U \right\}$$

$$F = \{\mu_F(u), u \in U\}$$


- Exemplo

$$F = \{(30,0), (35,0,3), (40,1), (45,1), (50,0,7), (55,0,4), (60,0)\}$$

$$F = \left\{ \left( \frac{0}{30} \right), \left( \frac{0,3}{35} \right), \left( \frac{1}{40} \right), \left( \frac{1}{45} \right), \left( \frac{0,7}{50} \right), \left( \frac{0,4}{55} \right), \left( \frac{0}{60} \right) \right\}$$

$$F = \{0,0.3,1,1,0.7,0.4,0\}$$

# Operações





## Variáveis linguísticas

- Uma variável linguística é uma variável cujos valores são palavras
- Uma variável linguística é definida por

$$\langle X, T(X), U, G, M \rangle$$

- X: nome, T(X):função de pertinência de X, U:universo de discurso, G: gramática, M: regras semânticas associadas

# Regras Fuzzy

- Relacionam variáveis fuzzy, cada uma delas associada a um dos seus predicados linguísticos
- SE **Velocidade é Baixa**  
ENTÃO **Aceleração é Alta**

# Base de conhecimento

- Base de dados: definições de conjuntos fuzzy
- Base de regras
- Exemplo de uma regra SE-ENTÃO:
  - Se Erro é Pequeno e Variação do erro é Baixa então:
  - posição da válvula tampão é ZERO.
  - Parte SE: antecedente
  - Parte ENTÃO: consequente

# Inferência e defuzzificação

- Operação de max-min
  - Inferência: Operador mínimo
  - Agregação: Operador máximo
- Defuzzificação
  - Centro de área